

FAD 核糖开关 GBSA 代理模型与昂贵实验闭环优化——生工实验团队对接汇报稿

用途：与生工实验团队对接，讨论如何利用有限、昂贵的新 GBSA（项目中的目标自由能指标）标签，迭代提升 RNA 核糖开关 GBSA 预测模型，并逐步建立可执行的模型—实验闭环。

建议汇报时长：25–35 分钟；讨论 20–40 分钟。

汇报定位：这不是“已经确定全部算法细节”的项目结题汇报，而是“提出一个有文献依据、可验证、可逐轮调整的实验—算法联合方案”，希望在会上确定实验容量、标签质量、迭代周期与第一轮候选数。

当前核心目标：第一阶段优先提高 GBSA 预测模型的泛化精度；第二阶段在代理模型足够可靠后，再逐步转向寻找更优 GBSA 序列。


0. 术语约定

为避免汇报中英文术语造成理解障碍，本文首次出现的重要英文术语均给出中文含义。

- **GBSA：**本项目的目标自由能指标；下文直接简称 GBSA。
- **Feature Selection（特征选择）：**从已有候选特征中筛选出与 GBSA 有效相关且信息不冗余的特征。
- **Feature Extraction / Representation（特征提取 / 表示学习）：**把 RNA 序列和筛选后的物理/结构特征表示成适合模型学习的向量。
- **Surrogate Model（代理模型）：**用较低成本预测昂贵目标函数（这里为 GBSA）的模型。
- **Bayesian Optimization, BO（贝叶斯优化）：**利用代理模型的预测和不确定性，迭代选择最值得真实评估的候选。
- **Active Learning, AL（主动学习）：**优先选择“最能提升模型认知”的样本进行标注。
- **Deep Ensemble（深度集成）：**训练多个独立神经网络，用多个模型的预测形成经验预测分布。
- **Uncertainty Quantification, UQ（不确定性量化）：**估计模型对某个预测有多大把握。
- **Upper Confidence Bound, UCB（置信上界）：**贝叶斯优化中兼顾预测值和不确定性的候选选择函数。
- **Lower Confidence Bound, LCB（置信下界）：**当目标是最小化某个值时使用的置信界选择函数。
- **Kriging Believer, KB（克里金信念批量策略）：**构造一批候选时，把已经选中的候选暂时用模型预测值作为“伪标签”加入模型，再继续选择下一个候选，从而降低批内重复。
- **Design–Build–Test–Learn, DBTL（设计—构建—测试—学习闭环）：**模型设计候选、实验构建与测试、结果返回、模型再学习的迭代流程。
- **Mutual Information, MI（互信息）：**衡量变量之间一般统计依赖关系，可捕获非线性、非单调关系。
- **Spearman Correlation（斯皮尔曼秩相关）：**衡量两个变量之间单调关系的非参数相关系数。
- **Principal Component Analysis, PCA（主成分分析）：**无监督线性降维方法。
- **Gaussian Process, GP（高斯过程）：**经典概率代理模型，可直接给出预测均值和不确定性。
- **Masked Language Modeling, MLM（掩码语言建模）：**随机遮盖部分序列片段，并让模型恢复被遮盖内容的自监督预训练任务。
- **Triplet Loss（三元组损失）：**使相似样本的表示更接近、不同样本的表示更远的一类度量学习损失。
- **Epistemic Uncertainty（认知不确定性）：**源于模型“没有见过或没学懂”的不确定性，可通过增加数据降低。
- **Aleatoric Uncertainty（数据噪声不确定性）：**源于实验或模拟本身噪声的不可约不确定性。
- **Retrospective Active-Learning Simulation（回顾性主动学习模拟）：**把已有标签暂时隐藏，用已知历史数据模拟未来主动学习过程，以验证候选选择方法和批量大小。

一、建议的汇报总体结构

建议把汇报主线固定为：



汇报的核心句建议统一为：

我们的目标不是一次性让模型“生成一批看起来最好的 RNA”，而是建立一个能够反复学习的昂贵标签闭环：每一轮优先选择最有信息价值的 RNA 获得真实 GBSA，使有限实验资源最大程度转化为模型泛化能力。

第 1 页：研究目标——从“预测模型”升级为“模型—实验闭环”

页面标题

面向昂贵 GBSA 标签的核糖开关迭代学习框架

英文副标题可写：

Expensive-Oracle Learning for Riboswitch GBSA（面向昂贵评价函数的核糖开关 GBSA 学习）

页面建议内容

目前已有约 2000 条带 GBSA 标签的 RNA 序列，核心预测任务为：

$$f_{\theta}(x) \rightarrow \widehat{\text{GBSA}}$$

其中：

- x ：RNA 序列以及与其相关的结构/物理特征；
- $\widehat{\text{GBSA}}$ ：代理模型预测值；
- 真实 GBSA 获取成本较高，因此无法对整个候选空间逐条真实评估。

本项目下一阶段的真正问题不是：


“Random Forest（随机森林）、XGBoost（极端梯度提升）还是 Transformer（变换器模型）哪个更好？”

而是：

“如果下一轮只能新获得 50、100 或 200 个昂贵 GBSA 标签，应该选择哪些 RNA，才能让后续模型提升最大？”

图怎么画

画一个左右对比图：



在右图上标注：

DBTL（设计—构建—测试—学习）闭环

现场讲稿

我们当前已经不是完全没有模型，而是模型已经能够学习到一定的 GBSA 排序信号。下一阶段最重要的问题，是如何把新增实验数据变成真正能够提高模型能力的数据。

因此我们希望实验团队不仅承担“最终验证”，而是和算法一起进入迭代闭环。每一轮模型根据现有认知选择最值得验证的序列；实验返回 GBSA 后模型重新训练，再决定下一轮。

这类问题在机器学习里属于 Active Learning（主动学习）和 Bayesian Optimization（贝叶斯优化）交叉的昂贵评价函数优化问题。

本页需要避免的说法

不要说：

“我们通过三轮实验一定可以做到 0.6。”

应该说：

“我们希望通过学习曲线验证模型能否逐轮突破当前瓶颈，0.6 是阶段性的高目标，而不是目前可以保证的结果。”

第 2 页：当前状态——为什么下一步不能只继续堆模型

页面标题

当前瓶颈：模型已经学到信号，但新增信息比继续堆模型更重要

页面建议内容


当前项目可以采用以下汇报口径：

- 已有约 **2000 条带 GBSA 标签的 RNA 序列**；
- RNA 长度约 **141 nt**；
- 设计空间主要由 **13 个可变位点**决定；
- 当前稳定评价应以多随机划分结果为主；
- 当前 GBSA 排序预测的稳定基准约为 **Spearman $\rho \approx 0.37$** 左右；
- 历史上某些单次划分可出现更高结果，但不能作为稳定泛化能力的证明；
- 已经测试过多种树模型、提升模型、支持向量模型和集成策略；
- 高维物理/结构特征中存在有效信号，但“把所有特征直接加入模型”并没有稳定提高最终表现。

注：如果会前最新正式实验结果有更新，建议把本页数字替换为最新冻结版本；原则是不使用单个最优 seed（随机种子）作为主要结果。

图怎么画

建议画一个“边际收益递减”示意图：



旁边写：

- 更多模型 ≠ 必然更多有效信息；
- 更多特征 ≠ 必然更高泛化性能；
- 当前需要改变的是 **有效标签覆盖** 和 **标签质量**。

现场讲稿

从目前结果看，我们面临的不只是“模型还不够复杂”。

如果一个问题的主要瓶颈是模型类型，那么 RF 换 XGB、XGB 换深度网络应该出现持续的大幅提升；但我们的实验更像是进入了平台期。

因此下一阶段的核心假设是：当前 2000 条 GBSA 对 13 位点组合空间的覆盖不足，尤其是某些互作区域和模型高不确定区域没有足够标签。

如果这个假设成立，那么有策略地新增一小批标签，应当比随机新增同样数量标签更有效。

第 3 页：总体方法——四个模块，而不是简单“做贝叶斯优化”

页面标题

技术路线：特征筛选 → 多模态表示 → 概率代理 → 批量主动学习

页面建议内容

建议正式把路线分成四层：

① Feature Selection（特征选择）

目标：

从现有物理、结构、序列衍生特征中找出与 GBSA 真实相关、稳定且低冗余的特征块。

方法：

Spearman + Mutual Information（互信息） → Stability（稳定性） → Redundancy Removal（去冗余）

② Representation / Fusion（表示学习 / 融合）

两条输入支路：RNA Sequence（RNA 序列）和 Selected Physics / Structure Features（筛选后的物理/结构特征），分别编码，再融合。

③ Probabilistic Surrogate（概率代理模型）

输出不只是一条预测，而是：

$\mu(x)$ 和 $\sigma(x)$


即：

- $\mu(x)$: 预测 GBSA;
- $\sigma(x)$: 模型对该预测的不确定程度。

④ Batch Active Learning / Bayesian Optimization（批量主动学习 / 贝叶斯优化）

根据模型当前知识选择下一批最有价值序列。

图怎么画



现场讲稿

我们希望把“贝叶斯”放在正确的位置。贝叶斯优化并不是简单换一个叫 Bayesian 的回归器，而是要求模型对未测序列同时给出预测和不确定性，然后利用不确定性决定下一批实验。

所以在进入昂贵优化之前，前面还有两个基础问题必须解决：哪些物理特征值得保留，以及 RNA 序列本身和物理特征应该怎么共同表达。

第 4 页：Feature Selection（特征选择）——Spearman + MI + 去冗余

页面标题

第一步：以“高相关、低冗余、跨划分稳定”为原则筛选物理/结构特征

4.1 为什么采用 Filter Method（过滤式特征选择）

导师提出的思路：

$$\text{Spearman} + \text{MI} \rightarrow \text{去除冗余}$$

是合理的，尤其适合当前目标：

- 候选特征种类有限；
- 很多特征来自不同物理/结构模块；
- 不希望为了筛一个特征就反复训练复杂模型；

- 希望筛选过程可解释、计算成本低、方便汇报。

上传的特征选择方案同样建议使用 Spearman 和 Mutual Information（互信息）评估与目标的关系，并对高相关特征去冗余。

4.2 为什么同时用 Spearman 和 MI

Spearman Correlation（斯皮尔曼秩相关）

衡量单调关系：

$$\rho_s(X, Y)$$

优点：

- 不要求线性；
- 对异常值通常比 Pearson（皮尔逊相关）更稳健；
- 与我们最终重视 Spearman 排序指标的方向一致。

局限：U 型、倒 U 型等非单调关系可能得到低相关。

Mutual Information（互信息）

衡量一般统计依赖：

$$I(X; Y)$$

优点：

- 可发现非线性关系；
- 可补 Spearman 对非单调关系的不足。

因此两者互补：

Spearman：单调依赖 + MI：一般非线性依赖

4.3 关键修改：以 Feature Block（特征块）为筛选单位

我们的某些“特征”并不是单个数，而是一个高维特征块，例如：

- wd：可能有数百维；
- motif_positional：数十维；
- pos_pair_prob：多维；
- contact_pca；
- energy_land；
- struct；
- mut；
- 其他 NUPACK（核酸热力学分析）相关特征。

不能把所有维度直接混在一起后简单取 Top-K（前 K 个），因为一个 208 维特征块比一个 5 维特征块更容易仅由于维度数量大而“碰巧”出现一个很高的相关维度。

因此建议：

37 类特征作为第一层筛选单位，而不是把全部几百/上千维直接当作同等级单变量。

4.4 推荐的 Block Score（特征块评分）

对于第 g 个特征块：

$$X_g \in \mathbb{R}^{N \times d_g}$$

在训练数据内部，对其中每一维 j 计算：

$$r_{g,j} = |\rho_s(X_{g,j}, Y)|$$

以及：

$$m_{g,j} = MI(X_{g,j}; Y)$$

为了避免“最大值偏好高维块”，不建议直接使用最大值，更推荐使用：

$$R_g = \text{mean}(\text{Top-}k\% r_{g,j})$$

$$M_g = \text{mean}(\text{Top-}k\% m_{g,j})$$

例如取每个特征块内部前 10%–20% 的维度做平均。

由于 Spearman 和 MI 数值尺度不同，不建议直接相加，而建议先在 37 个特征块间转成排名：

$$Score_g = 0.5 \cdot Rank(R_g) + 0.5 \cdot Rank(M_g)$$

这里的 0.5/0.5 是初始方案，可在回顾性实验中测试，但不要在实验数据上反复调到过拟合。

4.5 加入 Stability（稳定性）

只在一次完整数据上算特征排名不够。建议在多个训练划分中重复特征筛选，例如 20–30 个随机种子或 bootstrap（自助采样）。

对每个特征块统计：

$$Stability_g = \frac{\text{进入 Top-K 的次数}}{\text{总重复次数}}$$

例如：

- 特征 A：30 次中 27 次进入 Top-10，稳定性 0.90；
- 特征 B：30 次中 8 次进入 Top-10，稳定性 0.27。

优先保留 A。

核心原则：不是只选“相关最高”的特征，而是选“在不同数据划分下持续有用”的特征。

4.6 Redundancy Removal（去冗余）

导师提出 $|\rho(X_i, X_j)| > 0.85$ 则认为高度冗余，这个规则对单维特征很好用。

但对于高维特征块，需要先把每个特征块压缩成低维摘要。第一版推荐：

1. 对每个候选特征块单独做 PCA（主成分分析）；
2. 保留前 2–5 个主成分，或解释 80%–90% 方差；
3. 根据这些低维摘要判断特征块之间是否高度重复；
4. 如果两个块高度冗余，则优先保留与 GBSA 关联更强、跨 seed 更稳定、生物物理解释更明确、维度更低的一个。


第二版可作为方法学补充测试 Distance Correlation（距离相关）、CKA（中心化核对齐）或 HSIC（希尔伯特—施密特独立性准则），但明天汇报不需要把这些复杂方法作为主线。

4.7 防止 Feature Leakage（特征泄漏）

这一步必须强调：

Spearman、MI、去冗余阈值、PCA 都只能在训练 fold（训练折）内部拟合。

正确流程：



不能先用全部 2000 条筛特征，再做交叉验证，否则会高估模型能力。

4.8 本阶段建议产出

建议形成三级结果：

- Top 12–15：初筛集合；
- 经过冗余过滤后约 5–10 个核心 feature blocks（特征块）；
- 额外保留 1–3 个具有明确结构意义但单变量相关不高的 biological rescue features（生物学保留特征），用于防止纯过滤法遗漏互作信息。

现场讲稿

特征选择阶段我们不打算堆很多复杂算法。核心原则就是与 GBSA 有关系、彼此不要高度重复，而且这种关系在不同数据划分下要稳定。我们会特别按“特征块”来筛，而不是让维度大的特征天然占优势。同时我们会保留少数结构上合理、可能通过交互作用起效的特征，因为单变量 Spearman 和 MI 仍可能漏掉 epistasis（上位性 / 位点互作）。

第 5 页：Feature Representation（特征表示）——RNA 序列和物理特征怎么融合

页面标题

第二步：建立 Sequence–Physics Representation（序列—物理联合表示）

这一页是整个项目方法创新的核心之一。

5.1 RNA 序列的两层信息

设计空间主要由 13 个可变位点决定：

$$x = (x_1, x_2, \dots, x_{13}), \quad x_i \in \{A, C, G, U\}$$

最简单表示是 One-Hot Encoding（独热编码）：

$$13 \times 4 = 52$$

它必须保留为可靠基线。

但 13 个位点嵌入在约 141 nt 的 RNA scaffold（骨架）中，位点效应可能依赖相邻序列、配对位置、motif（基序）、长程结构背景以及 epistasis（上位性），所以需要测试学习型序列表示。

5.2 Main Sequence Encoder（主序列编码器）：参考 Kelvin et al. 2026

Kelvin 等人在 2026 年 Nucleic Acids Research（《核酸研究》）的核糖开关工作中采用：

- 3-mer tokenizer (3-mer 分词器)；
- BERT-like Transformer Encoder (类 BERT 变换器编码器)；
- 6 个 Transformer blocks (变换器模块)；
- embedding dimension (嵌入维度) 128；
- MLM (掩码语言建模)；
- Triplet Margin Loss (三元组间隔损失)；
- 使用 36,925 条 riboswitch (核糖开关) 序列预训练；
- [CLS] token (分类标记) 的 128 维输出作为 sequence embedding (序列嵌入)。

5.3 我们不能直接照搬，需要针对 FAD 修改

原论文 RNA 最长约 70 nt，而我们约 141 nt。同时我们最大的特殊性是 141 nt 中真正变化的主要只有 13 个设计位点。

如果完全照搬随机 MLM，大量 mask (掩码) 会落在几乎永远不变化的 scaffold (骨架) 位置，模型可能把能力浪费在“恢复固定序列”。因此建议比较两个版本。

Version A (版本 A)：Full-Length Encoder (全长编码器)

输入完整 141 nt：

$$141nt \rightarrow 3\text{-mer} \rightarrow Transformer$$

把论文中的 `max_sequence_length = 70` 改为适应约 141 token 的长度。

Version B (版本 B)：Mutation-Aware Encoder (突变感知编码器)

仍使用全长 RNA，但预训练时让 mask (掩码) 更集中于：

- 13 个可变位点；
- 可变位点附近局部窗口；
- 与可变位点可能形成配对的结构位置。

初始可尝试：70% masking (掩码) 来自突变相关区域，30% 保留普通随机 masking。

5.4 无标签候选序列也有价值

Transformer (变换器) 预训练不需要 GBSA 标签。因此如果我们已有数万到十万条候选序列，可以用于：

$$MLM + Triplet Learning \text{ (三元组学习)}$$


得到 FAD-specific encoder (FAD 专用序列编码器)。

候选池不仅是未来要搜索的空间，同时也是序列表征的自监督训练语料。

5.5 Physics Branch (物理特征支路)

经过第 4 页筛选后，假设留下 5–10 个 feature blocks (特征块)。不要再次把所有原始维度直接拼回去。

建议对每一个块单独压缩：



最终把所有物理块组合成：

$$z_{phys} \approx 20 \sim 40d$$

第一版优先使用 PCA 而不是复杂 autoencoder（自编码器），因为 2000 个有标签样本仍属小数据，PCA 不使用 GBSA 标签，泄漏风险和过拟合风险更低，同时易解释、易复现。

第 6 页：Feature Fusion（特征融合）——先简单，再逐步复杂化

页面标题

RNA Sequence（序列） + Physics（物理）如何融合：从可验证基线开始

6.1 必须做的三个 Ablation（消融实验）

Model A：Sequence Only（仅序列）

输入 z_{seq} ，确认序列表示本身能学到多少 GBSA 信息。

Model B：Physics Only（仅物理特征）

输入 z_{phys} ，确认筛选后的结构/物理信息单独能达到什么水平。

Model C：Sequence + Physics（序列 + 物理）

$$z = [z_{seq}; z_{phys}]$$

检验两种信息是否真正互补。

6.2 第一版建议：Early Fusion（早期融合 / 直接拼接）

例如：

$$z_{seq} = 128d, \quad z_{phys} = 32d$$

则：

$$z_{fusion} = 160d$$

然后进入小型回归网络：

$$160 \rightarrow 128 \rightarrow 64 \rightarrow 1 \text{ 个 GBSA}$$

或者：

$$160 \rightarrow 256 \rightarrow 128 \rightarrow 64 \rightarrow 1 \text{ 个 GBSA}$$

不建议直接照搬 Kelvin 论文的 9 层、每层 256 的回归网络，因为我们的监督标签只有约 2000 个，过深网络更容易过拟合。

6.3 第二阶段可尝试 Gated Fusion（门控融合）

如果直接拼接证明有效，再尝试让模型学习不同 RNA 上序列信息和物理信息的权重，例如：

$$g = \sigma(W[z_{seq}; z_{phys}])$$

但这不是第一阶段必须完成的工作。

现场讲稿

我们不想把所有东西混成一个 500 或 1500 维向量，然后完全依赖模型自己处理。更合理的是让 RNA 序列和结构物理信息成为两个信息源：序列支路负责学习突变组合和上下文，物理支路负责提供 NUPACK、能量、配对概率等显式物理信息。两支路都压到小维度后再融合，这样更适合我们 2000 条标签的规模，也更方便证明每一类信息到底有没有贡献。

第 7 页：直接对标论文——NAR 2026 的核糖开关 Deep Batch Bayesian Optimization

页面标题

直接相关工作：核糖开关已实现真实实验闭环的 Deep Batch Bayesian Optimization（深度批量贝叶斯优化）

核心文献：

Daniel Kelvin, Erik Kubaczka, Marianna Karava, Heinz Koepl, Beatrix Suess.

Iterative design of a NAND hybrid riboswitch by deep batch Bayesian optimization（利用深度批量贝叶斯优化迭代设计 NAND 混合核糖开关）
Nucleic Acids Research（核酸研究），2026, 54(5), gkag145.

DOI: 10.1093/nar/gkag145

开源：

- GitHub：Self-Organizing-Systems-TU-Darmstadt/NANDRiboswitchDesignByBayesOpt
- Zenodo：10.5281/zenodo.15185168

7.1 论文流程



7.2 关键数字

论文中：

- 预训练 RNA：36,925 条 riboswitch sequences（核糖开关序列）；
- candidate pool（候选池）：3,256 条；

- 初始 individually characterized（逐条实验表征）序列：**34 条**；
- ensemble size（集成模型数量）：**100**；
- batch size（每轮批量）：**16**；
- UCB coverage（置信覆盖率）：**95%**；
- 共做 3 轮 Bayesian optimization（贝叶斯优化）；
- 新增实验序列： $16 \times 3 = 48$ ；
- 总共约 82 条序列进入精细体内表征；
- 最优 NAND score（与非评分）从约 1.70 提高到 3.42。

7.3 论文真正值得借鉴的部分

不是简单“它用了 Transformer”，更重要的是四个模块：

1. **Task-specific Sequence Pretraining**（任务相关序列预训练）；
2. **Deep Ensemble Uncertainty**（深度集成不确定性）；
3. **Kriging Believer Batch Selection**（克里金信念批量选择）；
4. **DBTL Cycle**（设计—构建—测试—学习闭环）。

7.4 论文对我们的直接意义

这篇工作提供了强先验证据：

在 riboswitch（核糖开关）问题中，使用不确定性驱动的 batch Bayesian optimization（批量贝叶斯优化）进行多轮真实实验闭环是可行的。

我们真正需要验证的是：

把该框架改造成 GBSA 预测导向以后，是否能够比随机新增标签更快提高 FAD 的泛化性能。

第 8 页：Kelvin 2026 → FAD：四项关键改造

页面标题

从 NAND 核糖开关设计到 GBSA 学习：四项关键改造

Kelvin et al. 2026	FAD 拟采用方案
Hybrid riboswitch（混合核糖开关）	PreQ1 / RF00522 核糖开关
优化 P1 stem（P1 茎区）	主要优化 13 个可变位点组合
Sequence only（主要基于序列）	Sequence + Physics（序列 + 物理/结构）
4 个表达状态	1 个 GBSA 连续目标
NAND score 最大化	第一阶段提高 GBSA 预测精度
UCB（置信上界）	第一阶段 uncertainty-driven AL（不确定性主动学习）
UCB 找高性能序列	第二阶段可改为 LCB 找低 GBSA
100 个神经网络 ensemble（集成）	先从 20–50 个开始验证
16 条 / round（轮）	50 / 100 / 200 由离线模拟 + 实验容量决定
KB batch（克里金信念批量选择）	保留，并加入 physics-aware diversity（物理感知多样性）
wet-lab expression（实验表达量）	昂贵 GBSA / 实验真实标签

改造 1：Sequence-only → Sequence + Physics

Kelvin 论文主要用序列作为输入，而论文 Discussion（讨论）明确提出未来可以把 structural information（结构信息）整合进模型。

我们的优势是已有：

- NUPACK（核酸热力学计算）；
- structure（结构）；
- base-pair probability（碱基配对概率）；
- energy landscape（能量景观）；
- contact（接触）；
- motif（基序）；
- positional features（位置特征）等。

因此可构建：

$$Sequence\ Encoder + Selected\ Physics$$

改造 2：NAND Score → GBSA

原论文：

$$Sequence \rightarrow (\phi_{w/o}, \phi_{Tc}, \phi_{Neo}, \phi_{both}) \rightarrow NAND\ Score$$

我们：

$$Sequence + Physics \rightarrow GBSA$$

原论文的 Bernoulli KL divergence（伯努利 KL 散度）不适合我们的连续自由能目标。

建议第一版使用 Huber Loss（Huber 稳健回归损失），后续可测试：

$$L = L_{Huber} + \lambda L_{Rank}$$

改造 3：UCB Optimization（UCB 优化） → Active Learning First（先主动学习）

原论文目标是 $\max S(x)$ ，所以 UCB 适合找“可能非常好的序列”。

我们的当前首要目标是提高整体预测精度，所以第一阶段更应该找“模型最缺信息、测完后最可能提升泛化能力的序列”。

因此第一阶段 acquisition function（采集函数）应以：

$$\sigma_{epistemic}(x)$$

即认知不确定性为核心。

改造 4：Sequence Diversity → Physics-aware Diversity

Kelvin 论文后续分析发现，普通 Levenshtein distance（编辑距离）与功能差异关系有限，而 base-pair distance（碱基配对距离）与功能差异关系更强。

因此我们的批内多样性不应只看 Hamming distance（汉明距离），建议：

$$d(i, j) = \lambda_s d_{seq}(i, j) + \lambda_p d_{physics}(i, j) + \lambda_{str} d_{structure}(i, j)$$

这可以形成 **Physics-aware Batch Selection（物理感知批量选择）**。

第 9 页：Probabilistic Surrogate（概率代理模型）——“贝叶斯”到底怎么做

页面标题

代理模型选择：不仅比较预测精度，还必须比较不确定性是否可信

9.1 关键概念

Bayesian Optimization（贝叶斯优化）真正需要的是：

$$p(y \mid x, D)$$

即对未知序列给出预测分布，而不是单一数值。

我们希望得到：

$$\mu(x) = E[y \mid x, D]$$

和：

$$\sigma(x) = Uncertainty[y \mid x, D]$$

9.2 建议比较三类代理模型

Baseline 1：现有强传统模型

- Random Forest, RF（随机森林）；
- Extra Trees, ET（极端随机树）；
- Gradient Boosting, GBR（梯度提升回归）；
- XGBoost（极端梯度提升）；
- Support Vector Regression, SVR（支持向量回归）。

Baseline 2：Gaussian Process（高斯过程）

推荐测试 Matérn Kernel + ARD（Matérn 核 + 自动相关性确定）。

优点：概率定义清楚，天然输出均值与方差，适合小数据 Bayesian Optimization（贝叶斯优化）。

风险：特征维度和样本规模上升时计算成本增加；对复杂离散序列空间的表达可能不如学习型 encoder（编码器）。

Main Candidate：Deep Ensemble（深度集成）

训练：

$$M = 20 \sim 50$$

个独立模型，每个模型：

$$f_{\theta_m}(x) \rightarrow \widehat{GBSA}_m$$

得到：

$$\begin{aligned} \mu(x) &= \frac{1}{M} \sum_{m=1}^M \widehat{GBSA}_m(x) \\ \sigma_{ensemble}(x) &= Std[\widehat{GBSA}_1(x), ..., \widehat{GBSA}_M(x)] \end{aligned}$$

9.3 为什么不直接照论文用 100 个模型

Kelvin 论文采用 100 个模型用于构建稳定 empirical predictive distribution（经验预测分布）。但其计算复杂度与 ensemble size × batch size（集成规模 × 批量大小）相关。

我们的候选池更大、预期 batch 可能达到 50–100，因此建议：

- 1. 从 20 个集成成员开始；
- 2. 比较 20 / 50 / 100 的 uncertainty stability（不确定性稳定性）；
- 3. 如果 20 和 50 给出的候选排序已高度一致，就没有必要为形式上“复现论文”强行使用 100。

9.4 代理模型选择标准

不能只看 Spearman，至少同时看：

A. Prediction Accuracy（预测精度）

- Spearman correlation（斯皮尔曼相关）；
- MAE（平均绝对误差）；
- RMSE（均方根误差）。

B. Uncertainty Calibration（不确定性校准）

例如：

$$corr(\sigma(x), |\hat{y} - y|)$$

C. Coverage（覆盖率）

检查预测区间的真实覆盖率。

D. Active-Learning Efficiency（主动学习效率）

固定新增 100 个标签时，哪个代理最终让 frozen test（冻结测试集）的 Spearman 提升最多。

第 10 页：Kriging Believer（KB）——为什么不能一次直接拿“不确定性最高的前 100”

页面标题

批量实验的核心问题：100 条必须“信息互补”，而不是 100 个相似的高不确定序列

10.1 普通 Top-K 的问题

高不确定序列可能集中在同一个局部区域。一次实验测 100 个高度相似序列，相当于花 100 次成本重复回答一个问题。

10.2 Kriging Believer（克里金信念批量策略）

第一条：

$$x_1 = \arg \max A(x)$$

然后暂时假设：

$$y_1^{pseudo} = \mu(x_1)$$

把它加入训练集，更新代理模型，再选择第二条。如此重复直到形成：

$$B = \{x_1, x_2, \dots, x_m\}$$

实验返回后，用真实 GBSA 替换所有 pseudo labels（伪标签）。

10.3 对 FAD 的工程改造：KB-lite（轻量克里金信念）

如果 $M = 50$ 个 ensemble 模型且 batch=100，每选一个样本都完整重新训练 Transformer 会很重。

建议：

实验轮之间

真实 100 条 GBSA 回来后完整训练 encoder（编码器）+ physics branch（物理支路）+ regression head（回归头）。

同一实验 batch 内

进行 KB 时：

- 冻结 sequence encoder（序列编码器）；
- 冻结 physics representation（物理表示）；
- 只快速更新 regression head / uncertainty head（回归头 / 不确定性头）。

这样保留 KB 的核心作用，同时降低计算量。

第 11 页：Acquisition Function（采集函数）——先把模型学准，再找最优 GBSA

页面标题

候选选择分两阶段：Learning（学习）→ Optimization（优化）

Stage I: Bayesian Active Learning（贝叶斯主动学习）

当前目标：

提高全局 GBSA 预测精度

关注：

1. Epistemic Uncertainty（认知不确定性）；
2. Distance to Labeled Set（与已标注数据的距离）；
3. Batch Diversity（批内多样性）；
4. 少量 Exploitation（利用），保留当前预测有潜力的候选。

第一版混合采集函数不建议直接把不同量纲原值相加，而先转成 percentile rank（百分位排名）：

$$A_{learn}(x) = w_U R_U(x) + w_D R_D(x) + w_Q R_Q(x)$$

初始可测试：

$$w_U = 0.6, \quad w_D = 0.3, \quad w_Q = 0.1$$

这只是待验证初始值，应由回顾性模拟决定，而不是人为固定。

Stage II：Bayesian Optimization（贝叶斯优化）

当模型足够可靠后，如果目标是寻找更低 GBSA，可使用：

$$LCB(x) = \mu(x) - \beta\sigma(x)$$

即 Lower Confidence Bound（置信下界）。

整个项目可以自然从“提高模型精度”转向“用模型寻找最优序列”。

第 12 页：正式实验前，先用已有 2000 条做 Retrospective AL Simulation（回顾性主动学习模拟）

页面标题

先用历史真实标签回答三个问题：选什么？每轮多少？能提升多少？

12.1 为什么必须先做

目前我们仍不知道：

- 1. Uncertainty（不确定性）选择是否真的比 Random（随机选择）更有效？
- 2. KB（克里金信念策略）是否能带来额外收益？
- 3. batch=50、100、200 哪一个在本项目上最划算？
- 4. 新增 300 个标签有没有可能显著推动 Spearman？
- 5. 0.6 是否有任何数据驱动依据？

Kelvin 论文证明的是“贝叶斯优化可以找到性能更好的核糖开关”，它没有证明“能让我们的 GBSA held-out Spearman 从约 0.37 提高到 0.6”。所以必须用我们的历史数据做模拟。


12.2 推荐模拟设计

例如将 $N = 2000$ 划成：

- Initial Train（初始训练集）：1200；
- Simulated Candidate Pool（模拟候选池）：500；
- Frozen Test（冻结测试集）：300。

500 条候选真实 GBSA 暂时隐藏；300 条冻结测试集从头到尾不参与候选选择、特征筛选或参数选择。

12.3 模拟过程



12.4 必须比较的采集策略

- Random Sampling（随机抽样）；
- Greedy Predicted Best（贪心预测最优）；
- Uncertainty Sampling（不确定性采样）；
- Uncertainty + Diversity（不确定性 + 多样性）；
- UCB / LCB + KB（置信界 + 克里金信念）；
- Physics-aware Uncertainty + KB（物理感知不确定性 + KB）。

12.5 必须比较的 batch size（批量大小）

建议至少模拟：

25, 50, 100, 200

每种设置用 20-30 个随机种子，并保持总新增标签预算一致，例如总共 +400：

- batch 50：50×8；
- batch 100：100×4；
- batch 200：200×2。

12.6 最终关键图

横轴：Number of Acquired GBSA Labels（新增 GBSA 标签数）。

纵轴：Frozen-test Spearman（冻结测试集 Spearman）。

画 Random、Uncertainty、KB、Physics-aware KB 四条学习曲线。

如果同样新增 300 条后主动学习明显优于随机，才真正有依据投入新实验。

第 13 页：第一轮到底 50、96、100 还是 200？

页面标题

Batch Size（批量大小）不是固定常数：由实验吞吐量 + 离线学习效率共同决定

13.1 96 没有算法上的特殊意义

96 的常见来源是 96-well plate（96 孔板）实验格式，不是贝叶斯优化的数学要求。

Kelvin 论文实际 batch=16。其他主动学习实验也可以每轮几十到几百条。

所以：

如果实验平台适合 100 条，100 完全可以，而且从项目管理上比 96 更直观。

13.2 为什么不默认第一轮 200

如果总预算 200：

- 一次做 200：2000 → 2200，后 100 条仍由旧模型选择；
- 分两轮做 100：2000 → 2100 → 2200，第二个 100 利用了第一轮真实反馈。

理论上分轮更有机会提高信息效率，但分轮增加实验周期间隔和项目协调成本，所以最终要共同优化。

13.3 明天建议讨论三个候选

方案 A：50 / round（每轮 50）

反馈频繁，但实验轮数多。

方案 B：100 / round（每轮 100）

迭代和实验效率折中，目前最适合作为默讨论值。

方案 C：200 / round（每轮 200）

适合一次启动成本高、不能频繁实验的场景。

最终通过：

Retrospective Simulation + Wet – lab Constraints

共同决定。

13.4 如果使用 96 孔板

“96 个孔”不等于“96 个新序列”，必须预留 positive control（阳性对照）、negative control（阴性对照）、reference sequence（参考序列）、technical replicate（技术重复）、biological replicate（生物学重复）。因此每板真正的新序列可能只有 70–90，需要实验团队给出实际约束。

第 14 页：推荐的第一阶段闭环设计

页面标题

初步建议：先规划 3 轮，每轮约 100 条，但以离线模拟结果为准

如果实验容量允许，可以把项目预算先按 $3 \times 100 \approx 300$ 个新 GBSA 标签进行规划，但不是一次性承诺 300 条，而是设置 checkpoint（检查点）。

Round 0（第 0 轮）

已有 $N \approx 2000$ ，完成：

- 特征筛选；

- Sequence–Physics representation（序列—物理表示）；
- surrogate benchmark（代理模型比较）；
- uncertainty calibration（不确定性校准）；
- retrospective AL simulation（回顾性主动学习模拟）。

Round 1（第 1 轮）

模型选择约 100 条高信息量序列，实验返回后：

$2000 \rightarrow 2100$

重新完整训练全部模型，并检查 frozen benchmark、uncertainty、GBSA 分布覆盖和 mutation cluster（突变簇）表现。

Round 2 / 3

每轮重新计算 acquisition（采集值），不能重复使用上一轮排名，因为：

$p(y|x, D_{2100}) \neq p(y|x, D_{2000})$

第三轮后得到约 $N = 2300$ ，再判断是否继续到 400–500 新标签，或开始从 Active Learning（主动学习）切换到 Bayesian Optimization（贝叶斯优化）。

第 15 页：第一轮 100 条应该包含什么样的序列

页面标题


第一轮目标：最大化信息增益，而不是把 100 个名额全部给“预测最优”

如果回顾性模拟支持 hybrid strategy（混合策略），可采用如下初始构成讨论：

类型	参考数量	目的
High epistemic uncertainty（高认知不确定性）	45	解决模型最不会的区域
Coverage / novelty（覆盖 / 新颖性）	25	补足当前数据空间盲区
Physics-aware diversity（物理感知多样性）	与上述联合约束	避免选到物理上重复的 RNA
Predicted promising（预测有潜力）	20	保留实际优化价值
Random control（随机对照）	10	证明主动学习是否优于随机

注意：Diversity（多样性）更适合作为整个 batch 的约束，而不是机械单独划 20 条。

更严格的流程是：



第 16 页：GBSA Label Quality（标签质量）——0.6 能不能达到，取决于“可学习信号”有多少

页面标题

在追求更高 Spearman 前，必须估计 GBSA 标签本身的噪声上限

模型看到的可能是：

$$GBSA_{observed} = GBSA_{true} + \epsilon$$

其中 ϵ 可能来自实验测量噪声、MD（分子动力学）采样不足、初始构象差异、trajectory（轨迹）长度、replicate（重复）差异、protocol（实验/模拟协议）差异等。

建议实验团队共同建立 QC（质量控制）信息

对于一部分序列，尽量获取：

- replicate mean（重复均值）；
- replicate standard deviation（重复标准差）；
- protocol version（协议版本）；
- batch ID（实验批次编号）；
- failed / censored samples（失败 / 截断样本）；
- 质量评分。

如果可能，优先选择少量历史代表序列做 repeated measurement（重复测量），用于估计 $Var(\epsilon)$ 。

如果重复实验一致性很差，模型存在天然上限；反之，如果同一序列跨重复的排序一致性很高，则说明 0.6 至少不是被标签噪声直接否定的。

第 17 页：0.6 到底应该怎么表达

页面标题

Spearman 0.6：作为 Stretch Target（挑战目标），不作为实验承诺

当前稳定模型若约为 $\rho \approx 0.37$ ，那么 $0.37 \rightarrow 0.60$ 是非常大的提升。

不能因为某篇论文“目标性能翻倍”，就推导我们 Spearman 也能达到 0.6。Kelvin 论文优化的是 best NAND functionality（最佳 NAND 功能），不是 global held-out Spearman（全局留出集 Spearman）。

更严谨的目标定义

Minimum Success（最低成功）

主动学习显著优于随机新增同样标签：

$$\Delta\rho_{AL} > \Delta\rho_{Random}$$

Stage Goal（阶段目标）

$$0.37 \rightarrow 0.45+ \rightarrow 0.50+$$

Stretch Goal（挑战目标）

如果 learning curve（学习曲线）持续上升，并且 label noise（标签噪声）允许：

$\rho \sim 0.6$

现场建议说法

“0.6 是我们的挑战目标，但不是今天用理论直接保证的数字。我们会在正式消耗大量实验资源前，利用已有 2000 条标签做回顾性主动学习实验，建立 learning curve。第一、二轮新实验完成后再根据真实增益判断 0.6 是否可达以及需要多少新增样本。”

第 18 页：实验团队需要提供什么——数据接口必须一次定义清楚

页面标题

实验输出不仅要有 GBSA 数字，还要能用于机器学习质量控制

字段	说明
sequence_id	唯一编号
sequence	完整 RNA 序列
mutation_pattern	13 位点突变模式
gsa	最终目标值
replicate_id	重复编号
gsa_raw	每次重复原始值
gsa_mean	重复均值
gsa_std	重复标准差
protocol_version	实验 / 模拟协议版本
batch_id	实验批次
qc_status	质量控制状态
failure_reason	如失败，记录原因
date	完成日期

如果 GBSA 是由多个中间量计算得到，建议中间量也全部保留，不要只返回最后一列。

第 19 页：明天必须和实验团队确定的 10 个问题

页面标题

会后需要形成明确决策，而不是只讨论算法

- 1. 单轮最大可处理多少“新序列”？ 50 / 100 / 200 的实际工作量分别是多少？
- 2. 实验是否受 96-well plate（96 孔板）限制？ 如果受限，一块板能容纳多少真正的新序列？
- 3. 每条序列需要多少 biological replicates（生物学重复）和 technical replicates（技术重复）？
- 4. 单轮 turnaround time（周转时间）是多少？
- 5. 一次做 200 与分两次做 100，成本差多少？
- 6. 是否可以重复测量少量历史样本？ 用于估计标签噪声和批次效应。
- 7. 序列是否存在不可实验约束？ 如 GC 含量、长度、motif（基序）、二级结构、合成难度等。
- 8. GBSA 数据失败率大约多少？

9. 是否存在 **batch effect**（批次效应）？不同轮实验是否完全可比？
10. 第一阶段更优先“模型变准”还是“同时找最好序列”？建议明确第一阶段 KPI（关键绩效指标）。

第 20 页：项目实施路线图

页面标题

从现在到第一轮实验的建议实施顺序

Phase 1：Feature Selection（特征选择）

$$37\ blocks \rightarrow Spearman + MI \rightarrow stability \rightarrow redundancy \rightarrow 5 \sim 10\ blocks$$

输出：特征块排名、稳定性、冗余图、最终保留列表。

Phase 2：Representation Benchmark（表示方法比较）

比较：

1. 13-site one-hot（13 位点独热编码）；
2. full-sequence encoder（全序列编码器）；
3. mutation-aware encoder（突变感知编码器）；
4. physics-only representation（仅物理表示）；
5. sequence + physics fusion（序列 + 物理融合）。

Phase 3：Probabilistic Surrogate Benchmark（概率代理比较）

比较 GP（高斯过程）、Deep Ensemble（深度集成）、RF / XGB ensemble（树模型集成）。

指标：Spearman、MAE / RMSE、不确定性校准。

Phase 4：Retrospective AL Benchmark（回顾性主动学习评测）

比较 Random、Greedy、Uncertainty、UCB / LCB、KB、Physics-aware KB，同时比较 batch=25/50/100/200。

Phase 5：Round 1（第一轮真实昂贵标签）

根据离线模拟和实验容量，选择 50–100 条作为第一轮优先候选。

Phase 6：Iterative Learning（迭代学习）

真实数据返回后重新运行特征流水线、代理模型、不确定性评估、采集函数和下一轮候选选择。

第 21 页：本项目拟形成的方法学创新

页面标题

我们不是简单复现 Kelvin 论文，而是针对 GBSA 做方法扩展

Innovation 1（创新点 1）

Block-wise Stable Feature Selection（特征块级稳定筛选）：

$$Spearman + MI + Stability + Redundancy$$

用于高维异构 RNA 物理特征。

Innovation 2（创新点 2）

Sequence–Physics Fusion（序列—物理融合）：参考深度 RNA sequence encoder，同时引入 NUPACK、secondary structure（二级结构）、energy landscape（能量景观）、pairing probability（配对概率）、motif（基序）等。

Innovation 3（创新点 3）

Prediction-oriented Bayesian Active Learning（面向预测提升的贝叶斯主动学习）：Kelvin 的目标是最大化 NAND score，我们第一阶段改成最大化 information gain（信息增益），先提高 GBSA surrogate（代理模型）准确性。

Innovation 4（创新点 4）

Physics-aware Kriging Believer（物理感知的克里金信念批量选择）：批次多样性同时考虑 sequence + structure + physics（序列 + 结构 + 物理），避免“序列不同、物理状态重复”的实验浪费。

第 22 页：建议的结论页

页面标题

希望今天和实验团队共同确认的方案

1. 当前模型瓶颈需要从“继续堆模型”转向“高价值新增 GBSA 标签”。
2. 特征侧采用 Spearman + Mutual Information（互信息）+ 稳定性 + 去冗余，形成紧凑物理特征集合。
3. 模型侧参考 NAR 2026 核糖开关 deep batch Bayesian optimization（深度批量贝叶斯优化），构建 Sequence + Physics（序列 + 物理）的概率代理模型。
4. 实验前先用已有约 2000 条 GBSA 做 retrospective active-learning simulation（回顾性主动学习模拟），确定 acquisition（采集函数）和 50 / 100 / 200 的合理 batch size（批量大小）。
5. 正式建立“模型选择 → 昂贵 GBSA → 数据回流 → 重训 → 再选择”的 DBTL（设计—构建—测试—学习）闭环。

底部：

2000 → +100 → 2100 → +100 → 2200 → ...

- Primary KPI（主要指标）**：稳定 held-out Spearman（留出集斯皮尔曼相关）的逐轮提升。
- Stretch Target（挑战目标）**：约 0.6，但由实际 learning curve（学习曲线）决定。

二、建议的完整技术方案（备份页 / 会后技术文档）

23. Feature Selection（特征选择）的推荐算法规范

设共有 $G = 37$ 类特征块：

$$\mathcal{F} = \{F_1, F_2, \dots, F_G\}$$

每个特征块：

$$F_g \in \mathbb{R}^{N \times d_g}$$

目标 $y \in \mathbb{R}^N$ 为 GBSA。

外层验证

每个 seed 先划分：

$$D = D_{train} \cup D_{test}$$

所有 Feature Selection（特征选择）只在 D_{train} 内完成。

单块关联度

$$r_{g,j} = |\rho_s(F_{g,j}, y)|$$
$$m_{g,j} = MI(F_{g,j}; y)$$

定义：

$$R_g = \text{mean}(\text{Top } 20\% \ r_{g,j})$$
$$M_g = \text{mean}(\text{Top } 20\% \ m_{g,j})$$

也可比较 median（中位数）、Top-3 mean（前三平均）、Top-10% mean（前 10% 平均），通过 nested CV（嵌套交叉验证）确定最稳定方案。

Rank Fusion（排名融合）

$$S_g = 0.5 \cdot \text{rank}_\rho(g) + 0.5 \cdot \text{rank}_{MI}(g)$$

Stability Selection（稳定性选择）

重复 $K = 20 \sim 30$ 次：

$$Stability_g = \frac{1}{K} \sum_{k=1}^K I(g \in TopM_k)$$

Redundancy（冗余）

$$F_g \rightarrow PCA(F_g) \rightarrow Z_g$$

如果两个 block 的低维表示高度相似，则根据 target relevance（目标相关性）、stability（稳定性）、biological interpretability（生物学可解释性）和 cost（成本）保留一个。

防止纯 Filter（过滤法）漏掉 Interaction（交互）

可能存在：

$$F_a \not\rightarrow y, \quad F_b \not\rightarrow y, \quad F_a \times F_b \rightarrow y$$

所以保留少量具有明确物理意义的 interaction-prone blocks（可能存在交互的特征块），后续通过 ablation（消融）确认。

三、Sequence Encoder（序列编码器）改造建议

24. Baseline（基线）

13 位点 One-hot（独热编码）：

$$13 \times 4 = 52d$$

25. Kelvin-style Encoder（Kelvin 风格编码器）

原论文架构：3-mer tokenizer（3-mer 分词）、6-layer Transformer encoder（6 层变换器编码器）、 $d_{model} = 128$ 、4-head attention（4 头注意力）、MLM（掩码语言模型）、triplet loss（三元组损失）。

我们的修改：

- max_sequence_length 增加到适应 141 nt；
- 使用 FAD candidate pool（FAD 候选池）做自监督预训练；
- 对 mutation positions（突变位点）提高 masking probability（掩码概率）；
- 比较 encoder frozen（冻结编码器）和 fine-tuned（微调编码器）。

26. 为什么不是直接使用原论文 checkpoint（检查点）

原论文预训练语料来自其四环素—新霉素混合核糖开关体系，与 PreQ1 / RF00522 的 scaffold（骨架）、sequence distribution（序列分布）和 function（功能）不同。

因此原 checkpoint 可作为 transfer-learning baseline（迁移学习基线），但不应默认就是最佳 FAD encoder。更合理的主方案是使用我们自己的候选序列做 domain-specific self-supervised pretraining（领域专用自监督预训练）。

四、Regression Head（回归头）与 Loss（损失函数）

27. 第一版网络

$$z_{seq} \in \mathbb{R}^{128}, \quad z_{phys} \in \mathbb{R}^{20 \sim 40}$$

拼接后约 148–168 维，MLP（多层感知机）可采用：

$$160 \rightarrow 128 \rightarrow 64 \rightarrow 1$$

28. Loss（损失）

第一版：

$$L = L_{Huber}$$

第二版：

$$L = L_{Huber} + \lambda L_{rank}$$

其中 L_{rank} 为 pairwise ranking loss（成对排序损失），用于增强排序一致性。

五、Deep Ensemble（深度集成）设计

29. Ensemble Diversity（集成多样性）

建议每个成员至少在 random initialization（随机初始化）、mini-batch order（小批次顺序）方面不同；bootstrap resampling（自助重采样）作为可选实验。

30. 是否训练 Encoder（编码器）

初始阶段

encoder 固定，只训练 regression head（回归头），防止 2000 标签破坏预训练表示，也降低 ensemble 训练成本。

后续阶段

比较 frozen encoder（冻结编码器）、last 1–2 Transformer blocks fine-tuning（最后 1–2 层微调）、full fine-tuning（全量微调），由验证结果决定。

六、Uncertainty Quantification（不确定性量化）必须单独验证

31. 不能把 ensemble std（集成标准差）自动当作“正确不确定性”

建议将测试样本按 $\sigma(x)$ 分成五组，比较各组 MAE。如果最不确定组误差显著更高，说明 uncertainty 有效。

32. Calibration（校准）

检查 50%、80%、90% prediction interval（预测区间）的真实覆盖率。必要时使用 conformal calibration（保形校准）等方法后处理。

七、Physics-aware KB（物理感知 KB）的建议算法

设 $\mathcal{X}_{pool}$ 为尚未获得昂贵 GBSA 的候选池。

对每条候选预先计算 sequence embedding（序列嵌入）、physics embedding（物理嵌入）、current mean prediction（当前均值预测）和 current uncertainty（当前不确定性）。

第一个候选：

$$x_1 = \arg \max_x A(x)$$

加入 pseudo observation（伪观测）：

$$(x_1, \mu(x_1))$$

对于后续候选，与已选集合 S 保持足够距离：

$$d(x, S) = \min_{s \in S} [\lambda_s d_{seq}(x, s) + \lambda_p d_{phys}(x, s)]$$

如果 $d(x, S) < \tau$ ，降低候选优先级。重复直到 $|S| = B$ ，随后整批交给实验。真实 GBSA 返回后删除伪标签并完整重训。

八、Retrospective Simulation（回顾性模拟）的统计设计

33. 多 seed（随机种子）

建议 20–30 组不同划分，汇报 mean（均值）、median（中位数）和 95% bootstrap CI（95% 自助置信区间）。

34. Random Split（随机划分）之外增加 Cluster Split（簇划分）

普通随机划分可能让训练集和测试集包含几乎相同的 mutation pattern（突变模式）。

因此建议同时做：

- Random Split（随机划分）：一般泛化；
- Cluster Split（簇划分）：按 mutation pattern / sequence distance（突变模式 / 序列距离）划分，评估新区域泛化。

主动学习的真实价值可能在 cluster split 上更明显。

九、Stopping Criteria（停止标准）

建议预先定义：

- 1. **Prediction Plateau（预测平台期）**：连续两轮 $\Delta Spearman < 0.01$ 且增益不稳定；
- 2. **Uncertainty Saturation（不确定性饱和）**：候选池大部分样本不确定性已明显下降；
- 3. **Active Learning $\approx$ Random（主动学习与随机接近）**；
- 4. **Experimental Cost（实验成本）**：每提升 0.01 Spearman 的成本过高；
- 5. **转向 Optimization（优化）**：预测精度已满足需求，开始把采集重点转向低 GBSA 候选。

十、明天可能被追问的问题及答辩话术

Q1：为什么是 96？100 不可以吗？

96 没有算法上的特殊意义，主要来自 96 孔板实验格式。贝叶斯优化本身不要求 96。Kelvin 的核糖开关论文每轮实际只选择 16 条。对我们来说 100 完全可以。我们希望先用已有 2000 条做回顾性主动学习模拟，比较 50、100、200 的信息效率，再结合实验团队一次实验的真实吞吐量决定。如果使用 96 孔板，还要给阳性、阴性对照和重复实验留位置，因此 96 个孔也通常不等于 96 个新序列。

Q2：为什么这些新序列能够提高模型？

关键不在于“多 100 条”本身，而在于这 100 条是不是补在模型真正缺数据的地方。随机加数据可能重复已有分布；主动学习利用模型不确定性找到模型最不会的区域，再利用序列和物理多样性避免重复。我们不会只凭理论假设这一点成立，而会先把已有 2000 条标签隐藏一部分做回顾性模拟，直接比较主动学习和随机抽样在同样新增样本数量下谁的 held-out Spearman 提升更多。

Q3：0.6 凭什么？

目前没有充分证据保证 0.6。0.6 应定义为 Stretch Target（挑战目标）。我们首先要求主动学习显著优于随机新增数据，然后看 learning curve（学习曲线）。如果从 2000 增加到 2100、2200、2300 的过程中 Spearman 仍持续稳定上升，同时 GBSA 重复测量表明标签噪声允许达到更高相关，那么 0.6 才有数据依据。如果学习曲线在 0.45 或 0.5 附近饱和，也应接受真实数据上限。

Q4：为什么不直接照 Kelvin 论文用 UCB？

因为优化目标不同。Kelvin 的目标是尽快找到 NAND score 最高的序列，所以 UCB 合适。我们当前第一目标是提高 GBSA 代理模型整体预测准确性，因此采集更应该优先选择模型最不确定、最缺覆盖的区域。等模型足够准确以后，再逐渐转成 LCB 寻找低 GBSA 候选。

Q5：为什么还要保留随机样本？

少量随机样本是重要对照。如果所有序列都由算法选择，最后即使模型变好了，也难以证明是主动学习有效还是单纯“多了 100 个标签”就会提高。保留约 5%–10% random control（随机对照）可以估计主动学习相对随机采样的真实增益。

Q6：为什么不用一个最准的 XGBoost，非要做 Bayesian（贝叶斯）？

如果只做一次预测，可以只选 Spearman 最高的模型。但主动学习还需要回答模型在哪里最没有把握。普通单个 XGBoost 主要输出点预测，不天然提供可靠的认知不确定性。因此下一阶段模型选择要同时看“预测准不准”和“不确定性可信不可信”。如果最后 XGB ensemble（XGB 集成）在预测和不确定性上都更好，我们也不会为了形式上做贝叶斯优化而强行使用神经网络。

Q7：为什么不直接使用 Gaussian Process（高斯过程）？

GP 是很好的概率基线，而且我们会保留。但我们的 RNA 是离散序列，同时还有结构/物理高维信息；Kelvin 论文已经证明 deep ensemble 在核糖开关闭环中可以有效工作。所以我们计划让 GP、deep ensemble 和现有树模型集成都参加统一 benchmark，最终根据预测精度、不确定性校准和主动学习效率选择。

Q8：为什么要加入 NUPACK / 结构特征？论文只用序列也成功了。

一方面，我们自己的已有实验表明物理/结构特征中存在与 GBSA 有关的信息，只是大量高维特征直接堆叠并不稳定。另一方面，Kelvin 论文在讨论中明确提出未来可整合结构信息，而且其分析显示更结构化的 base-pair distance 与功能变化关系更强。对 GBSA 这种物理自由能目标，结构和热力学信息具有更直接的机制关联，所以我们计划先筛掉冗余，再以低维形式与序列融合。

Q9：100 条为什么不全部选高 uncertainty？

因为高不确定序列可能高度集中在同一区域。模型可能对一组只差一个碱基的序列都很不确定，但测完其中几条以后，剩下的边际信息快速下降。所以我们计划使用 Kriging Believer 加 sequence/physics diversity，让整批 100 条互相补充，而不是简单做 uncertainty Top-100。

Q10：实验团队返回什么数据最有利于模型？

除最终 GBSA 外，我们最希望保留每次重复原始值、实验批次、协议版本和 QC。模型最终能达到多高不仅取决于样本数量，也取决于标签噪声。如果可以估计同一序列重复测量方差，我们就能判断误差中多少来自模型没学好，多少来自实验本身不可约噪声。

十一、建议在会上展示的关键参考文献

[1] Kelvin et al., 2026 ——最直接的 riboswitch（核糖开关）对标

Kelvin D, Kubaczka E, Karava M, Koepl H, Suess B.

Iterative design of a NAND hybrid riboswitch by deep batch Bayesian optimization（利用深度批量贝叶斯优化迭代设计 NAND 混合核糖开关）. *Nucleic Acids Research*（核酸研究）. 2026;54(5):gkag145.

DOI: 10.1093/nar/gkag145 .

关键借鉴：RNA sequence encoder（RNA 序列编码器）、deep ensemble（深度集成）、uncertainty quantification（不确定性量化）、UCB（置信上界）、Kriging Believer（克里金信念批量策略）、DBTL（设计—构建—测试—学习）闭环以及真实多轮核糖开关 wet-lab validation（湿实验验证）。

开源仓库：<https://github.com/Self-Organizing-Systems-TU-Darmstadt/NANDRiboswitchDesignByBayesOpt>

Zenodo: 10.5281/zenodo.15185168

[2] Groher et al., 2019 ——riboswitch + ML + biophysical features（核糖开关 + 机器学习 + 生物物理特征）

Groher A-C, Jager S, Schneider C, et al.

Tuning the Performance of Synthetic Riboswitches using Machine Learning（利用机器学习调控合成核糖开关性能）. *ACS Synthetic Biology*（ACS 合成生物学）. 2019;8(1):34–44.

DOI: 10.1021/acssynbio.8b00207 .

关键借鉴：机器学习预测 riboswitch switching behavior（核糖开关切换行为），并结合 biophysical parameters（生物物理参数）和序列模式。

[3] Angenent-Mari et al., 2020 ——大规模 RNA sequence-to-function（序列到功能）

Angenent-Mari NM, Garruss AS, Soenksen LR, et al.

A deep learning approach to programmable RNA switches（可编程 RNA 开关的深度学习方法）. *Nature Communications*（自然·通讯）. 2020;11:5057.

DOI: 10.1038/s41467-020-18677-1 .

关键借鉴：91,534 条 toehold switches（趾端开关）数据；深度神经网络直接学习 RNA sequence-to-function（RNA 序列到功能）。

注意：其有标签数据远多于我们的约 2000 条，所以不能用它证明“2000 条一定适合训练大型 Transformer”。

[4] Valeri et al., 2020 ——RNA sequence-to-function frameworks（RNA 序列到功能框架）

Valeri JA, Collins KM, Ramesh P, et al.
Sequence-to-function deep learning frameworks for engineered riboregulators（工程化 RNA 调控元件的序列到功能深度学习框架）.
Nature Communications（自然·通讯）. 2020;11:5058.
DOI: 10.1038/s41467-020-18676-2 .

[5] Yang et al., 2025 ——Active Learning（主动学习）真实实验闭环

Yang J, Lal RG, Bowden JC, et al.
Active learning-assisted directed evolution（主动学习辅助定向进化）.
Nature Communications（自然·通讯）. 2025;16:714.
DOI: 10.1038/s41467-025-55987-8 .

关键借鉴：low-N batch setting（小样本批量场景）、uncertainty-guided selection（不确定性驱动选择）、多轮实验—模型迭代。

注意：对象是蛋白质，主要用于支持主动学习的通用实验设计原则。

[6] Andersen et al., 2026 ——昂贵 MMGBSA + Bayesian Optimization（贝叶斯优化）

Andersen L, Rausch-Dupont M, Martínez Leon A, et al.
Accelerating ligand discovery by combining Bayesian optimization with MMGBSA-based binding affinity calculations（通过结合贝叶斯优化与基于 MMGBSA 的结合亲和力计算加速配体发现）.
Digital Discovery（数字发现）. 2026;5:3082–3095.
DOI: 10.1039/D5DD00522A .

关键借鉴：昂贵 MD/MMGBSA（分子动力学 / MMGBSA）作为 oracle（真实评价函数），代理模型选择少量候选进行昂贵计算，新标签返回后更新模型。

注意：对象是 protein–ligand（蛋白质—配体），不是核糖开关；主要用于支持“昂贵自由能计算 + 主动学习”范式。

[7] Stanton et al., 2022 ——Biological Sequence Bayesian Optimization（生物序列贝叶斯优化）

Stanton S, Maddox W, Gruver N, et al.
Accelerating Bayesian Optimization for Biological Sequence Design with Denoising Autoencoders（利用去噪自编码器加速生物序列设计的贝叶斯优化）.
ICML（国际机器学习大会）. 2022;162:20459–20478.

关键借鉴：离散生物序列空间中的 Bayesian Optimization（贝叶斯优化）、latent representation（潜在表示）以及 explore–exploit tradeoff（探索—利用平衡）。

十二、参考文献在汇报中的使用建议

如果时间有限，正文只重点讲三篇：

- 1. Kelvin et al., NAR 2026：同对象——riboswitch；同方法——batch Bayesian optimization；有真实 wet-lab loop；有完整开源代码。
- 2. Groher et al., ACS Synthetic Biology 2019：直接说明 riboswitch 功能与 biophysical features（生物物理特征）结合机器学习的可行性。
- 3. Andersen et al., Digital Discovery 2026：直接说明昂贵 MMGBSA 可以进入 active-learning / BO（主动学习 / 贝叶斯优化）闭环。

其余放备份页或参考文献页。

十三、明天汇报可以直接使用的开场稿

我们当前希望解决的问题，不只是继续寻找一个更强的 GBSA 回归模型，而是如何最大化每一个新增昂贵标签的价值。

目前我们已有约 2000 条带 GBSA 的核糖开关序列，并且已经进行了多类序列、结构和物理特征构建。下一步我们首先会通过 Spearman、互信息和冗余分析把特征空间收紧；然后分别建立 RNA 序列表示和物理特征表示，构建能够同时预测 GBSA 和输出不确定性的代理模型。

我们最近找到了一项 2026 年发表在 Nucleic Acids Research 的直接相关工作。它已经在真实核糖开关体系中采用深度集成、Kriging Believer 和批量贝叶斯优化完成了三轮实验闭环。因此我们希望以它作为核心参考框架，但针对我们的 GBSA 任务做关键改造：第一，我们加入 NUPACK 等结构物理信息；第二，我们输出 GBSA 而不是 NAND 功能评分；第三，我们第一阶段以提升模型预测精度为目标，所以候选选择将更偏向主动学习和信息增益，而不是直接追求当前预测最优值；第四，我们希望把序列多样性升级为结构和物理多样性。

在真正让实验团队投入大量资源之前，我们还会先用已有 2000 条真实 GBSA 做回顾性主动学习模拟，比较随机、UCB、不确定性、Kriging Believer 和我们拟采用的物理感知策略，并直接比较每轮 50、100 和 200 条的效率。这样我们希望让第一轮实验的规模和候选选择都有数据依据。

十四、建议的结束稿

今天希望和实验团队确定的不是一个最终固定算法，而是闭环接口。

算法侧我们负责从现有数据中建立可靠的概率代理模型，并在每一轮给出一批具有明确选择理由的 RNA；实验侧最关键的是确定单轮容量、重复数、实验周期、质量控制和数据返回格式。

如果这个闭环跑通，我们后续评估的不只是“有没有找到几个好序列”，还可以量化每新增 100 个 GBSA 标签到底带来了多少模型提升，以及主动学习是否显著优于随机采样。

最终目标是把当前一次性的 GBSA 建模任务升级成一个可以持续自我改进的 RNA 设计平台。

十五、最终推荐方案摘要

计算主线

Feature Selection（特征选择） → Sequence-Physics Representation（序列—物理表示） → Probabilistic Surrogate（概率代理） -

特征选择

$$Spearman + MI + Stability + Redundancy\ Removal$$

序列表示

$$13 - site\ One - hot\ vs\ FAD - specific\ Transformer\ Encoder$$

物理表示

$$Selected\ Blocks \rightarrow PCA \rightarrow 20 \sim 40d$$

概率代理

主候选：Deep Ensemble（深度集成）， $M = 20 \sim 50$ 。

同时保留 GP（高斯过程）和 RF/XGB Ensemble（树模型集成）作为 baseline（基线）。

第一阶段 Acquisition（采集）

$$Epistemic\ Uncertainty + Coverage + Physics - aware\ Diversity + Kriging\ Believer$$

第二阶段 Acquisition（采集）

代理模型足够准确后：

$$LCB + KB$$

用于寻找更优 GBSA 序列。

实验批次

不预设 96，优先比较：

$$50, 100, 200$$

通过：

$$Retrospective\ AL\ Simulation + Experimental\ Constraints$$

确定。

0.6 的表述

$$0.6 = Stretch\ Target\ (\text{挑战目标})$$

真正决策依据是：

$$Learning\ Curve + Label\ Noise\ Ceiling$$

十六、资料来源与开源实现

1. Kelvin D, Kubaczka E, Karava M, Koepl H, Suess B. **Iterative design of a NAND hybrid riboswitch by deep batch Bayesian optimization（利用深度批量贝叶斯优化迭代设计 NAND 混合核糖开关）**. *Nucleic Acids Research（核酸研究）*. 2026;54(5):gkag145. DOI: 10.1093/nar/gkag145 .

2. Kelvin et al. 开源代码： <https://github.com/Self-Organizing-Systems-TU-Darmstadt/NANDRiboswitchDesignByBayesOpt>

3. Kelvin et al. Zenodo 归档： <https://doi.org/10.5281/zenodo.15185168>

4. Groher A-C, Jager S, Schneider C, et al. **Tuning the Performance of Synthetic Riboswitches using Machine Learning（利用机器学习调控合成核糖开关性能）**. *ACS Synthetic Biology（ACS 合成生物学）*. 2019;8(1):34–44. DOI: 10.1021/acssynbio.8b00207 .

5. Angenent-Mari NM, Garruss AS, Soenksen LR, et al. **A deep learning approach to programmable RNA switches（可编程 RNA 开关的深度学习方法）**. *Nature Communications（自然·通讯）*. 2020;11:5057. DOI: 10.1038/s41467-020-18677-1 .

6. Valeri JA, Collins KM, Ramesh P, et al. **Sequence-to-function deep learning frameworks for engineered riboregulators（工程化 RNA 调控元件的序列到功能深度学习框架）**. *Nature Communications（自然·通讯）*. 2020;11:5058. DOI: 10.1038/s41467-020-18676-2 .

7. Yang J, Lal RG, Bowden JC, et al. **Active learning-assisted directed evolution（主动学习辅助定向进化）**. *Nature Communications（自然·通讯）*. 2025;16:714. DOI: 10.1038/s41467-025-55987-8 .

8. Andersen L, Rausch-Dupont M, Martínez Leon A, et al. **Accelerating ligand discovery by combining Bayesian optimization with MMGBSA-based binding affinity calculations（通过结合贝叶斯优化与 MMGBSA 结合亲和力计算加速配体发现）**. *Digital Discovery（数字发现）*. 2026;5:3082–3095. DOI: 10.1039/D5DD00522A .

9. Stanton S, Maddox W, Gruver N, et al. **Accelerating Bayesian Optimization for Biological Sequence Design with Denoising Autoencoders（利用去噪自编码器加速生物序列设计的贝叶斯优化）**. *ICML（国际机器学习大会）*. 2022;162:20459–20478.

十七、汇报前最后检查清单

在正式汇报前，建议把下列数字更新成当前最新版本：

- ☐ 当前 canonical GBSA 标签样本数；
- ☐ 当前正式 30-seed / 100-seed Spearman；

- ☐ 37 个 feature blocks（特征块）的最新完整名单；
- ☐ 每个 feature block 的维度；
- ☐ 当前候选池真实可用数量；
- ☐ 是否所有候选都有 NUPACK 特征；
- ☐ 实验 GBSA 的具体获得流程；
- ☐ 是否存在 replicate（重复）；
- ☐ 当前一次实验的最大吞吐量；
- ☐ 50 / 100 / 200 的实验成本和周期；
- ☐ 哪些序列约束必须在模型候选生成前过滤；
- ☐ 实验团队希望第一阶段优先提高模型精度，还是同时强调发现低 GBSA 序列。

文档版本说明：本方案把 Kelvin et al. 2026 的真实核糖开关 deep batch Bayesian optimization（深度批量贝叶斯优化）作为核心直接对标，但没有把其方法机械照搬到 FAD。文中明确区分了“原论文已经证明的部分”和“FAD 需要通过回顾性模拟 / 新实验验证的改造部分”。特别是 Spearman $\approx$ 0.6，目前只应视为挑战目标；最终可达性能必须由新增标签 learning curve（学习曲线）与 GBSA label noise（标签噪声）共同判断。